Infnet

Kevin William Alves Rodrigues

Projeto da Disciplina

Relatório técnico integrado

Visão Computacional com CNNs e Transformers [26E3_3]

A1 a A4: implementações, resultados e estudos de caso de raio-X e tráfego urbano. Versão para revisão do autor.

10/10/2026

Resumo

Este relatório reúne quatro atividades de visão computacional com CNNs e Transformers. A1 compara um Vision Transformer didático, treinado do zero, com um ViT pré-treinado no mesmo Test de Fruits-360: as acurácias foram 99,61% e 99,09%, com F1 macro de 0,9968 e 0,9908. A2 usa CLIP, sem treinamento adicional, para ranking e busca semântica em 300 anúncios do ADS-16. A inspeção dos resultados mostrou falsos positivos e sensibilidade ao limiar; os scores não foram tratados como probabilidades de presença. A3 treina apenas a cabeça de uma ResNet-50 congelada e registra 270 acertos em 271 imagens de teste. Em A4, uma cGAN gera imagens condicionadas em COVID para uma comparação pareada entre classificadores, com três sementes. O recall médio foi 80,39% nos dois braços. A ablação de normalização espectral e suavização melhorou modestamente os diagnósticos de diversidade, sem demonstrar benefício clínico. O estudo de tráfego examina um cenário de 800 frames e doze câmeras e propõe um protocolo de coleta, avaliação e operação; não há resultados experimentais. Os capítulos distinguem medições, interpretações e propostas, com atenção aos limites das partições e à generalização para dados externos.

Palavras-chave: visão computacional; Vision Transformer; CLIP; transferência de aprendizado; cGAN; avaliação experimental.

Sumário

1 Introdução e objetivos....3

2 Ambiente e metodologia de execução....4

3 A1 Vision Transformers para classificação de frutas....6

4 A2 Reconhecimento semântico e busca com CLIP....13

5 A3 Classificação de objetos com ResNet 50....17

6 A4 Estudo de caso de raio X e geração sintética....20

7 A4 Estudo de caso de tráfego urbano....25

8 Discussão integrada e conclusões....27

9 Referências....29

10 Apêndices técnicos....30

1 Introdução e objetivos

Contextualização

A visão computacional extrai informação de imagens para classificação, recuperação de conteúdo e análise de cenas. Neste projeto da disciplina Visão Computacional com CNNs e Transformers, essas tarefas são examinadas por implementações executáveis e evidências dos notebooks. O objetivo é relacionar os modelos às decisões de avaliação e aos limites dos dados.

As atividades abrangem frutas em condições controladas, anúncios, objetos e geração sintética de radiografias. Tráfego urbano complementa o escopo como proposta analítica. Cada tarefa exige seu próprio protocolo; seus valores de desempenho não constituem uma comparação direta entre arquiteturas.

Objetivo geral e objetivos específicos

O objetivo geral é implementar e analisar abordagens de visão computacional, documentando como os dados, o treinamento ou a inferência e a avaliação sustentam as conclusões. Em A1, o objetivo específico é construir os componentes de um ViT e comparar um modelo do zero com um modelo pré-treinado no mesmo conjunto de teste. Nas demais atividades, pretende-se examinar o alinhamento texto-imagem, a extração de características de uma CNN, a contribuição de dados sintéticos e os requisitos de uma aplicação de tráfego.

Tabela 1 — Escopo e critérios de avaliação do projeto.

Atividade	Abordagem e pergunta	Evidência principal
A1	ViT: o ajuste de um modelo pré-treinado supera o modelo didático neste recorte?	Accuracy, top-3, precision, recall e F1 no mesmo Test
A2	CLIP: como texto e imagem apoiam a busca semântica de anúncios?	Ranking, sensibilidade ao corte e inspeção visual
A3	ResNet-50: como uma cabeça treinada usa um backbone congelado?	Desempenho no teste e análise de erros
A4 — raio-X	cGAN: dados sintéticos alteram o desempenho da classificação?	Comparação por sementes e diagnósticos da geração
A4 — tráfego	Proposta analítica: como estruturar a análise de cenas urbanas?	Dados, desenho do sistema e protocolo proposto; sem execução

Organização e limites da versão

O capítulo 2 descreve o ambiente e a execução. Os capítulos 3 a 7 analisam as atividades e os estudos de caso. A discussão integrada reúne as conclusões; referências e apêndices permitem conferir os métodos, as métricas completas e os arquivos de origem.

2 Ambiente e metodologia de execução

Ambiente local e rastreabilidade

Os experimentos foram executados localmente, no Windows, e os notebooks preservam as saídas que fundamentam este relatório. A análise de A1 utiliza a execução v3 de 08/10/2026, com auditoria do checkpoint pré-treinado e exportação das métricas. A tabela 2 reproduz o ambiente registrado em projeto-1/resultados/v3/ambiente.json; essas versões identificam a execução de A1, não um ambiente uniforme comprovado para todas as atividades.

Tabela 2 — Ambiente registrado na execução de A1.

Componente	Registro
python	3.12.6
torch	2.9.0+cu130
torchvision	0.24.0+cu130
transformers	5.17.0
cuda	13.0
gpu	NVIDIA GeForce RTX 3050 6GB Laptop GPU

A2 utiliza a execução v3 em CPU, A3 mantém a execução v2 e A4 utiliza os registros de 08/10/2026. Cada capítulo identifica seus próprios dados e resultados. O estudo de tráfego é uma análise do documento da atividade 4.2, sem treinamento ou métricas experimentais.

Recursos e duração

Tabela 3 — Estimativas de planejamento dos notebooks, com dados em cache.

Atividade	RAM sugerida	VRAM sugerida	Duração estimada
A1	16 GB	6 GB	45–150 min
A2	8 GB	2 GB; 6 GB recomendados	2–10 min
A3	8 GB	4 GB; 6 GB recomendados	3–15 min
A4 — raio-X	8 GB	4 GB; 6 GB recomendados	10–35 min

Os valores da tabela 3 são referências de planejamento e não picos de uso medidos ou requisitos mínimos demonstrados. A2 também admite inferência em CPU. Em A1, os logs do Trainer registraram aproximadamente 564,3 s para o ajuste da cabeça e 3.015 s para o fine-

tuning completo, cerca de 9,4 e 50,3 minutos, respectivamente. Esses tempos se referem às fases de treinamento registradas, sem equivaler à duração integral do notebook. Não há medição consolidada de pico de RAM ou VRAM nos artefatos citados.

Protocolo de avaliação

A execução de A1 fixa a semente 42, mantém as classes e a ordem de avaliação e confere a disjunção dos caminhos de treino, validação e teste. O Training oficial fornece treino e validação; o Test oficial fica reservado para a comparação final. As transformações aleatórias são aplicadas somente ao treino, enquanto validação e teste usam transformações determinísticas. Os dois modelos recebem as mesmas partições e a mesma normalização.

O fluxo experimental é: seleção do recorte → divisão do Training → treinamento → escolha do checkpoint por F1 macro de validação → restauração e auditoria → avaliação final no Test. A validação orienta a parada e a seleção dos pesos; as métricas do teste descrevem os modelos escolhidos após essas decisões. Os CSVs e as saídas incorporadas ao notebook permitem conferir os valores apresentados sem repetir o treinamento.

Accuracy expressa a proporção de acertos; top-3 verifica a presença da classe real entre as três maiores pontuações. Precision e recall caracterizam, respectivamente, a confiabilidade das previsões de uma classe e a cobertura dos seus exemplos. F1 combina esses dois critérios. A média macro atribui o mesmo peso às 20 classes, enquanto a média ponderada considera seus suportes. A análise de erros e atenção complementa as métricas, sem demonstrar isoladamente relações causais.

3 A1 Vision Transformers para classificação de frutas

Dados e divisão experimental

A atividade utiliza Fruits-360, obtido do cache oficial do KaggleHub, dataset moltean/fruits, versão 107. O recorte fixo reúne 20 classes, incluindo variedades de maçã, banana, pimentão e tomate, além de abacate, kiwi, limão, abacaxi e morango. Embora o título da atividade mencione frutas, os rótulos selecionados incluem também pimentões. Os nomes completos e a distribuição por classe estão registrados no notebook. A documentação do dataset é descrita por Mureșan e Oltean (2018).

Tabela 4 — Partições de A1.

Conjunto	Imagens	Origem e função
Training original	10.856	Conjunto oficial antes da divisão
Treino	9.227	85% do Training; atualização dos pesos
Validação	1.629	15% do Training; seleção do checkpoint
Teste	3.634	Test oficial; avaliação final

A divisão estratificada, com semente 42, preservou aproximadamente as proporções das classes: a maior diferença absoluta entre Training e validação foi de cerca de 0,0003. A auditoria confirmou ausência de caminhos compartilhados entre os três conjuntos. Essa conferência impede a reutilização direta do mesmo arquivo, mas não elimina a possibilidade de correlação entre imagens visualmente próximas ou obtidas em condições de captura semelhantes.

As imagens originais de 100 × 100 pixels foram convertidas para RGB. No treino, foram usados recorte aleatório redimensionado para 224 × 224, escala de 0,8 a 1,0, espelhamento horizontal e rotação de até 15°. Na avaliação, foi aplicado apenas redimensionamento para 224 × 224. A normalização utiliza média e desvio 0,5 nos três canais, compatíveis com o processador do checkpoint pré-treinado. O redimensionamento não recupera detalhes ausentes na imagem original.

Arquitetura do Vision Transformer didático

O ViT transforma a imagem em uma sequência de patches, permitindo que um encoder Transformer processe relações entre regiões. Na implementação, uma projeção convolucional com kernel e passo 16 representa cada patch por um vetor de 192 componentes. A entrada de 224 × 224 produz 196 patches, organizados em uma grade de 14 × 14. Um token de classificação [CLS] é acrescentado ao início e embeddings posicionais aprendidos indicam a localização dos tokens, totalizando uma sequência de 197 elementos.

Cada uma das seis heads possui projeções Q, K e V independentes, com dimensão 32. Q representa a consulta de um token; K fornece as chaves com as quais ela é comparada; V contém a informação agregada. Os produtos entre Q e K são divididos pela raiz quadrada de 32

e normalizados por softmax. Os pesos resultantes ponderam V. Os contextos das heads são concatenados e projetados de volta para a dimensão 192, permitindo combinar diferentes relações entre tokens.

O encoder tem seis blocos, com normalização, atenção, conexões residuais e uma rede feed-forward com fator de expansão 4. O dropout é 0,1. Ao final, a representação normalizada de [CLS] alimenta uma camada linear com 20 saídas. O modelo tem 2.859.092 parâmetros treináveis. O desenho segue o princípio de classificação por patches de Dosovitskiy et al. (2020), em uma configuração menor e voltada ao estudo dos componentes.

As verificações executadas confirmaram patches com forma [2, 196, 192], sequência com [CLS] de comprimento 197, logits [2, 20] e atenção [2, 6, 197, 197] em cada bloco. Também foram conferidos a normalização dos pesos por linha, a equivalência numérica do produto escalar escalado, a independência das heads, a concatenação, as conexões residuais e a propagação de gradientes.

Treinamento e transferência de aprendizado

Tabela 5 — Configuração e seleção dos modelos de A1.

Aspecto	ViT do zero	ViT pré-treinado
Modelo	6 blocos; 6 heads; embedding 192	google/vit-base-patch16-224-in21k
Inicialização	Pesos inicializados no experimento	Backbone pré-treinado em ImageNet-21k; cabeça para 20 classes
Lote de treino	16 imagens	1 imagem; acumulação de 16 passos
Taxa inicial	3×10^{-4}, AdamW	Cabeça: 10^{-3}; completo: 2×10^{-5}
Orçamento / execução	Até 15 épocas / 8 executadas	Cabeça: 2 / 2; completo: 5 / 3
Early stopping	3 épocas sem melhora	2 avaliações sem melhora
Melhor validação	Época 5; F1 macro 0,995077	Fine-tuning, época 1; F1 macro 1,000000

No modelo didático, AdamW usa weight decay 0,05 e agendamento cosseno da taxa de aprendizado. A perda é entropia cruzada com label smoothing 0,1. Foram usados precisão mista e clipping do gradiente em 1,0. A validação oscilou durante as oito épocas: o melhor F1 ocorreu na quinta, enquanto a oitava terminou com cerca de 0,8975. Assim, o modelo avaliado foi o melhor estado salvo, e não o último estado do treinamento.

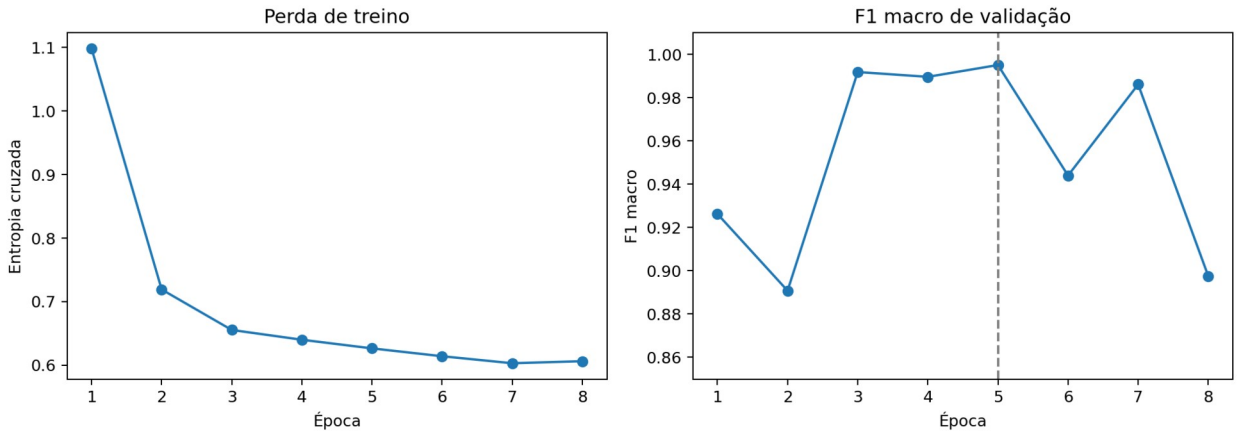


Figura 1 — Evolução da perda de treino e do F1 macro de validação do ViT didático. O checkpoint selecionado corresponde à época 5. Fonte: elaboração a partir do CSV de histórico da execução v3 de A1.

O segundo modelo utiliza o checkpoint ViT-Base com patches de 16 pixels e entrada 224 × 224, pré-treinado em ImageNet-21k. A cabeça de classificação foi adaptada para as 20 classes. Primeiro, o backbone foi congelado e somente classifier.weight e classifier.bias foram atualizados por duas épocas. Em seguida, o backbone foi inteiramente descongelado para o fine-tuning com taxa menor. Precisão mista, acumulação de gradientes e gradient checkpointing permitiram adequar o treinamento à GPU local de 6 GB.

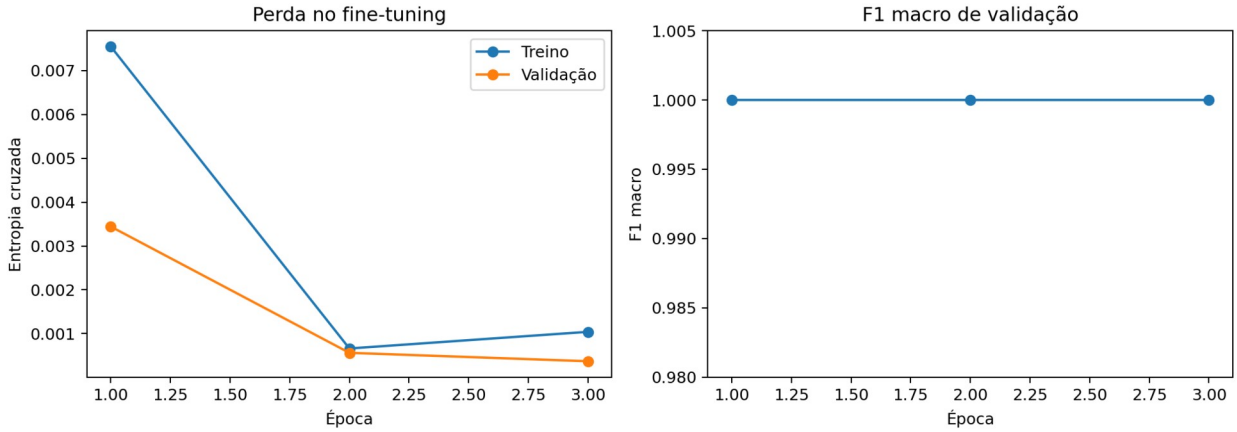


Figura 2 — Evolução do fine-tuning completo do ViT pré-treinado. O F1 macro de validação atingiu 1,0 na primeira época e permaneceu empatado nas seguintes. Fonte: elaboração a partir dos logs da execução v3 de A1.

Restauração auditada dos checkpoints

A seleção do modelo pré-treinado foi feita por F1 macro, com restauração do melhor checkpoint ao final de cada fase. A execução corrigida emprega a API oficial from_pretrained para converter os nomes das camadas salvos no checkpoint. Depois, carrega o estado com strict=True e compara cada tensor com o estado restaurado. A auditoria verificou 200 tensores em cada fase, sem chaves ausentes, inesperadas, incompatíveis ou erros de carregamento, e confirmou igualdade integral dos pesos.

Na fase da cabeça, checkpoint-1154 reproduziu F1 macro de validação 0,9820923699. No fine-tuning, checkpoint-577 reproduziu 1,0. Os valores recalculados coincidiram com os selecionados, com tolerância de 10^{-8} na conferência. O primeiro checkpoint do fine-tuning permaneceu selecionado porque as épocas seguintes empataram em F1, mesmo com perda de validação menor. Isso explica por que a menor loss não determinou o estado usado no teste.

Resultados no Test oficial

Tabela 6 — Métricas dos checkpoints selecionados no mesmo Test, com 3.634 imagens.

Métrica	ViT do zero	ViT pré-treinado
Accuracy	0,996147	0,990919
Top-3 accuracy	1,000000	1,000000
Precision macro	0,997035	0,993605
Recall macro	0,996742	0,989687
F1 macro	0,996846	0,990835
Precision ponderada	0,996284	0,992081
Recall ponderado	0,996147	0,990919
F1 ponderado	0,996162	0,990707

O ViT do zero acertou 3.620 imagens e errou 14; o pré-treinado acertou 3.601 e errou 33. A diferença de acurácia foi de aproximadamente 0,52 ponto percentual em favor do modelo didático. Ambos tiveram top-3 de 100%, indicando que, em todos os exemplos, a classe real estava entre as três maiores pontuações. Esse resultado não equivale a 100% de acerto na decisão top-1.

A comparação favorece o ViT do zero neste recorte e nesta execução. O F1 perfeito da validação do pré-treinado não assegurou o melhor desempenho no Test: a seleção usa um conjunto finito e as duas partições podem conter exemplos com dificuldades distintas. a comparação envolve modelos com tamanhos, inicializações e procedimentos de otimização diferentes. Sem repetições por sementes, intervalos de incerteza ou um controle de orçamento equivalente, não se conclui superioridade geral de treinar do zero sobre transferência de aprendizado.

Confusões e inspeção dos erros

As métricas por classe mostram que o pré-treinado obteve recall 0,79375 em Tomato 4, correspondente a 127 acertos entre 160 exemplos: os 33 erros do modelo pertencem a essa classe. O recall das demais classes foi 1,0. O ViT do zero apresentou quedas menores em Pepper Red 1, Tomato 1, Tomato 2 e Tomato 4; algumas previsões incorretas também reduziram a precisão de Tomato 3 e Strawberry 1. Esses padrões orientam a inspeção visual, mas não demonstram por si sós a causa das confusões.

Tabela 7 — Classes reais com erros no Test, obtidas dos recalls e suportes registrados.

Classe	Erros: do zero	Erros: pré-treinado
Pepper Red 1	3 / 222	0 / 222
Tomato 1	7 / 246	0 / 246
Tomato 2	1 / 225	0 / 225
Tomato 4	3 / 160	33 / 160

O notebook contém o procedimento para exibir matrizes normalizadas por classe real e até seis erros de maior score softmax de cada modelo. As saídas preservadas registram essas figuras como objetos de visualização, sem incorporar os pixels das galerias. Por isso, a análise apresentada aqui utiliza as métricas exportadas por classe. As matrizes e galerias completas poderão ser incorporadas aos apêndices quando houver exportação rastreável dessas imagens. O score softmax serve para ordenar os casos, mas não foi calibrado como probabilidade de correção.

Interpretação da atenção

Foi inspecionada a head 0 da última camada dos dois modelos sobre a mesma imagem: o exemplo 0 do Test, Apple Braeburn 1, classificado corretamente por ambos. O mapa utiliza os pesos da consulta [CLS] para os 196 patches, reorganizados na grade 14 × 14 e sobrepostos à imagem processada. Trata-se de uma head individual, sem média entre heads.

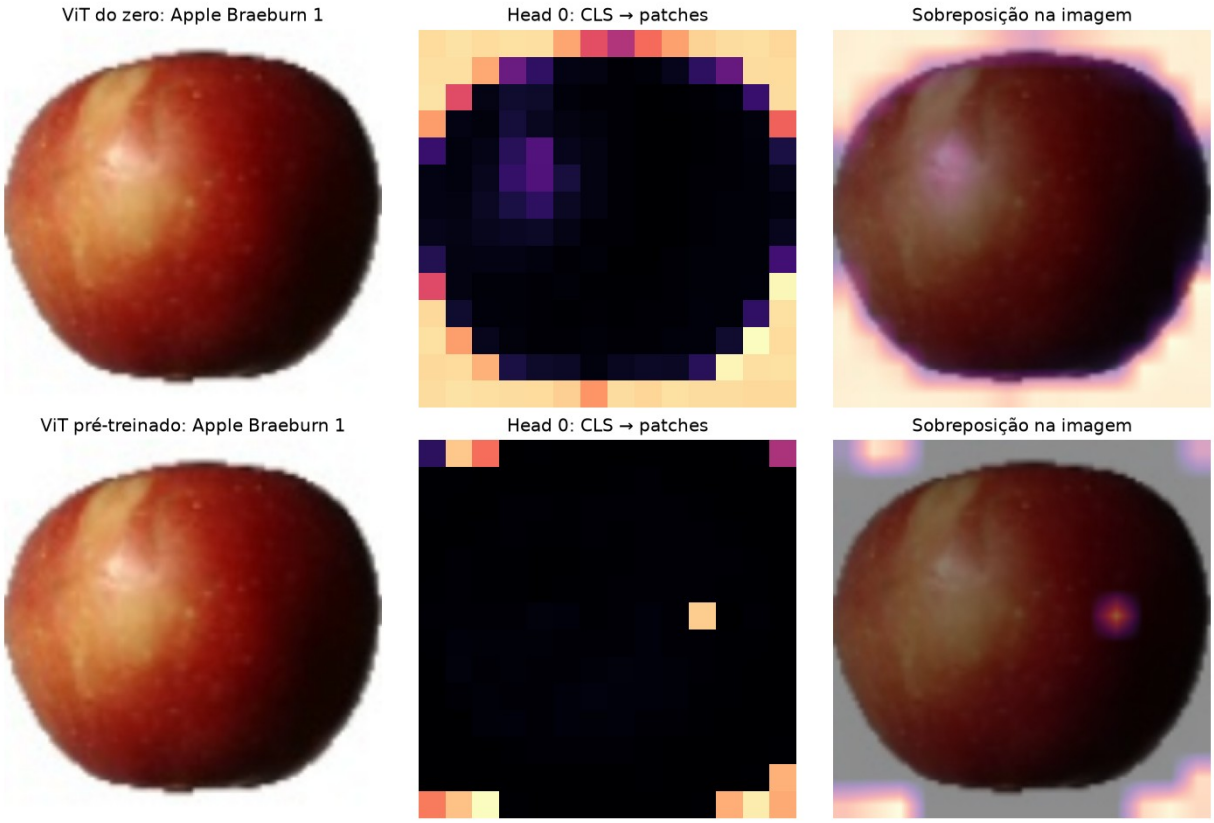


Figura 3 — Imagem processada, heatmap e sobreposição da atenção de [CLS] aos patches, head 0 da última camada. Cada mapa é normalizado para visualização. Fonte: execução v3 de A1.

No modelo do zero, essa head atribuiu maior peso a regiões do fundo próximas ao contorno; no pré-treinado, destacaram-se áreas do fundo e uma região pontual da fruta. A classificação correta coexistiu com atenção fora do centro do objeto. O mapa não deve ser interpretado como segmentação da fruta ou prova causal da decisão. A normalização individual também impede comparar diretamente magnitudes entre modelos, e a head 0 de um modelo não tem necessariamente a mesma função da head 0 do outro.

Relação com BERT, DeiT e Swin

BERT e ViT utilizam encoders Transformer para contextualizar tokens, com representações posicionais e possibilidade de usar [CLS] na classificação. Em BERT, os tokens representam texto e o pré-treinamento aprende representações bidirecionais da linguagem; em ViT, representam patches de imagem. A analogia explica o mecanismo de sequência, mas não implica que o objetivo de pré-treinamento ou os dados sejam os mesmos (Devlin et al., 2018; Dosovitskiy et al., 2020).

DeiT investiga treinamento eficiente em dados e introduz distilação por um token que recebe orientação de um professor. Swin usa uma organização hierárquica com atenção em janelas deslocadas, articulando relações locais e comunicação entre janelas. São alternativas conceituais para eficiência e representação visual; nenhuma foi treinada nesta atividade. Seus resultados publicados não são incorporados à tabela experimental de A1 (Touvron et al., 2020; Liu et al., 2021).

Limitações e conclusão de A1

Fruits-360 apresenta fundo predominantemente branco e condições controladas. O recorte de 20 classes não representa toda a diversidade do dataset, nem imagens de prateleiras com oclusão, iluminação variável e objetos sobrepostos. A disjunção de arquivos é necessária, porém uma divisão por sessão ou objeto capturado ajudaria a examinar correlações entre quadros. As curvas também mostram instabilidade da validação do modelo do zero, reforçando a importância da seleção do checkpoint.

Para escolher entre ViT e CNN em uma aplicação, devem ser considerados dados disponíveis, existência de pré-treinamento adequado, custo de memória, latência e avaliação no domínio real. A atenção global permite relações entre patches; as convoluções fornecem uma estrutura local que pode ser útil em cenários com poucos dados. A1 não contém um baseline CNN no mesmo protocolo, portanto não resolve empiricamente essa escolha. Próximos experimentos poderiam comparar uma CNN e um ViT menor, repetir sementes, medir latência e memória e avaliar imagens externas com fundos variados.

A implementação verificou os componentes do ViT e permitiu comparar os checkpoints no mesmo Test. O modelo do zero teve F1 macro 0,9968, contra 0,9908 do pré-treinado. O F1 perfeito na validação deste último não se repetiu no teste. As curvas e os erros mostram por que a conclusão deve ficar restrita à execução registrada.

4 A2 Reconhecimento semântico e busca com CLIP

Corpus e contrato de dados

A atividade utiliza ADS-16, disponível no Kaggle e associado ao benchmark de Roffo e Vinciarelli (2016). A busca local selecionou somente os diretórios de anúncios, deixando fora as fotografias pessoais de participantes. Foram encontrados 301 candidatos. O slot excedente Ads/1/16.png foi excluído conforme o contrato do notebook; os 300 restantes tinham hashes SHA-256 distintos e foram verificados como imagens legíveis. O corpus final reúne 20 categorias, com 15 anúncios em cada uma.

Esse conjunto difere do enunciado antigo que mencionava 16 categorias e 500 imagens. A análise usa o conteúdo efetivamente auditado, sem duplicar arquivos para atingir o número esperado. Não há divisão de treino e teste: o checkpoint permanece fixo e é usado para inferência sobre todo o corpus. Também não são utilizadas as avaliações de preferência dos participantes para treinar um recomendador.

Como CLIP relaciona texto e imagem

CLIP aprende representações de imagem e texto por pré-treinamento contrastivo: pares correspondentes são aproximados no espaço de embeddings, enquanto pares não correspondentes são separados (Radford et al., 2021). Nesta execução, openai/clip-vit-base-patch32 foi carregado em modo de avaliação e dentro de torch.inference_mode(). Nenhum peso foi atualizado. O processador do checkpoint preparou imagens RGB e textos.

Cada imagem produziu um vetor de 512 componentes. Os vetores de imagens e textos foram normalizados pela norma L2; seu produto interno, assim, corresponde à similaridade de cosseno. A matriz de imagens tem forma 300 × 512, e a comparação com 20 descrições gera uma matriz 300 × 20. A ordem das linhas foi mantida vinculada aos caminhos do catálogo. Essa correspondência é necessária para que um score seja associado à imagem correta.

As descrições e as oito consultas foram fixadas em inglês. CLIP usa tokenização BPE, enquanto BERT usa WordPiece. Ambos acrescentam tokens especiais e usam padding para combinar sequências de tamanhos diferentes. A attention mask identifica as posições válidas. No encoder textual do CLIP, uma máscara causal interna restringe a atenção e o embedding textual é obtido no final da sequência; BERT contextualiza o texto nos dois sentidos. O processador prepara essas entradas, sem construção manual de máscaras no notebook (Hugging Face, documentação de CLIP).

Ranking e sensibilidade ao limiar

Para cada conceito, a frequência semântica é o número de anúncios cujo score alcança o corte. Foram comparados 0,20, 0,25 e 0,30; o ranking final utiliza 0,25. Os empates são ordenados pela similaridade média e depois pelo nome do conceito. Essa frequência descreve correspondência com um prompt. Sem anotações de presença, não é uma contagem validada de objetos.

Tabela 8 — Cinco conceitos líderes de A2, corte 0,25.

Conceito	Imagens ≥ corte	Taxa	Score médio
isolated_product	197	65,67%	0,2580
people_using_product	164	54,67%	0,2525
text_logo	114	38,00%	0,2389
package	75	25,00%	0,2361
person	56	18,67%	0,2265

Tabela 9 — Efeito do limiar nas contagens dos cinco líderes.

Conceito	0,20	0,25	0,30
isolated_product	298	197	4
people_using_product	298	164	2
text_logo	273	114	3
package	285	75	0
person	245	56	2

Um corte menor inclui correspondências fracas; um maior reduz a cobertura. A tabela 9 mostra que a frequência depende fortemente dessa escolha. Não há rótulos de presença para estimar precision ou recall dos conceitos. Uma futura validação precisaria anotar uma amostra independente e escolher o limiar em dados de desenvolvimento, mantendo outra amostra para avaliação.

Na execução v3, feita em CPU com dois threads, people_using_product contou 164 imagens. A v2 em CUDA registrou 163, com os mesmos dados, prompts e corte. Uma imagem próxima de 0,25 mudou de lado por diferenças numéricas entre dispositivos. A ordem dos líderes e os caminhos das oito buscas foram preservados. A inferência e a exportação das figuras levaram aproximadamente 66 segundos, sem incluir toda a inicialização do ambiente.

O que a inspeção visual confirmou

Os três maiores scores de cada conceito foram exibidos automaticamente. Há falhas claras: os líderes de isolated_product incluem anúncios com mais de um produto ou apenas texto. Em people_using_product, uma pessoa posando e anúncios de serviços não confirmam o uso do produto descrito. O anúncio Fiat Ads/2/11.png aparece como pessoa, embora a peça mostre carro e logotipo. Texto, marca ou contexto publicitário podem aproximar embeddings sem que o elemento solicitado esteja visível.

Tabela 10 — Leitura dos exemplos líderes; inspeção restrita à galeria.

Conceito	Evidência observada	Interpretação
isolated_product	Ads/10/15: três hambúrgueres; Ads/10/11: hambúrguer e copo	Os líderes não confirmam um único produto em fundo liso
people_using_product	Ads/20/15: mãos e celular; Ads/20/11: pessoa posando	Interação parcial não confirma uso do serviço anunciado
text_logo	Ads/10/11, Ads/2/11 e Ads/10/15: slogans e marcas	Presença visual confirmada; dominância é subjetiva
package	Ads/3/11, Ads/17/11 e Ads/4/14: recipientes e caixas	Embalagens visíveis
person	Ads/20/11 e Ads/17/11: pessoas; Ads/2/11: carro	Dois positivos e um falso positivo

Uma galeria complementar reúne um positivo inspecionado por conceito, escolhido sem substituir os líderes ou recalcular as frequências. Os cinco ficaram acima do corte: relógio em Ads/13/7, jogador usando calçados em Ads/18/12, texto e marca Fiat em Ads/2/11, embalagens Colgate em Ads/4/14 e pessoa no Badoo em Ads/20/11. Caminhos, hashes e critérios estão no CSV de confirmação. Cinco casos positivos não validam todas as ocorrências do ranking.



Figura 4 — Positivos inspecionados que complementam o ranking automático. Os scores são similaridades, não probabilidades de presença. Fonte: A2, execução v3.

Busca por consultas e limites da recuperação

A busca compara o vetor de uma consulta com os 300 vetores de imagem e retorna as cinco maiores similaridades, com caminhos distintos e scores em ordem decrescente. O top-5 independe do corte de 0,25 usado nas contagens. Sempre retornar cinco resultados não significa que os cinco atendam à consulta. O apêndice A preserva todas as consultas e seus scores.



Figura 5 — Top-5 de "a car driving outdoors". Os resultados tratam de acessórios e peças automotivas; a consulta não foi atendida literalmente. Fonte: A2 v3.

A consulta sobre um carro em movimento ao ar livre recuperou anúncios da categoria automotiva, mas as peças exibidas falam de acessórios e não mostram a cena solicitada. É um exemplo de afinidade temática sem correspondência literal. Consultas com termos como saudável, luxo ou aventura exigem ainda mais cuidado: o score não certifica propriedades do produto ou a intenção de quem vê o anúncio.

A2 produziu um mecanismo de recuperação rastreável, com ranking e busca no mesmo espaço de embeddings. Seu limite aparece nos próprios resultados: a relação semântica pode ser útil para explorar o corpus, mas a presença de objetos e a relevância de cada resposta precisam de avaliação com critérios humanos definidos. Não foram medidos precision@5, recall de recuperação ou satisfação de usuários.

5 A3 Classificação de objetos com ResNet 50

Dados e protocolo

O Images Dataset foi obtido por KaggleHub, no identificador pavansanagapati/images-dataset, versão 1. A auditoria selecionou deterministicamente uma coleção de 1.803 imagens legíveis, sem somar duas árvores equivalentes do pacote. As classes foram descobertas a partir dos diretórios: bike, cars, cats, dogs, flowers, horses e human. As dimensões variavam de 80 a 1.920 pixels na largura e de 89 a 2.048 na altura.

Tabela 11 — Classes de A3 e recall no teste.

Classe	Corpus	Teste	Acertos	Recall
bike	365	55	54	98,1818%
cars	420	63	63	100,0000%
cats	202	30	30	100,0000%
dogs	202	30	30	100,0000%
flowers	210	32	32	100,0000%
horses	202	31	31	100,0000%
human	202	30	30	100,0000%

A divisão estratificada usa semente 42 e proporções-alvo de 70/15/15. O arredondamento resultou em 1.261 imagens de treino, 271 de validação e 271 de teste. Todas as classes estavam presentes nas partições, cujos caminhos eram disjuntos. As imagens foram convertidas para RGB, redimensionadas para 224 × 224 e normalizadas com média [0,485; 0,456; 0,406] e desvio [0,229; 0,224; 0,225]. Não foi aplicada augmentation no baseline.

Feature extraction com ResNet-50

ResNet utiliza conexões residuais para aprender transformações adicionadas à representação de entrada, facilitando o treinamento de redes profundas (He et al., 2015). Nesta atividade, ResNet50_Weights.IMAGENET1K_V2 fornece o backbone. Seus parâmetros foram congelados, e fc foi substituída por uma camada linear de 2.048 entradas e sete saídas. Somente fc.weight e fc.bias receberam gradientes e atualizações.

Congelar parâmetros não basta para preservar um backbone com BatchNorm: suas estatísticas também podem mudar em modo de treino. O notebook mantém a BatchNorm em avaliação. Esse cuidado torna a execução compatível com feature extraction. O domínio de objetos e animais oferece uma justificativa para começar com pesos ImageNet, mas o desempenho precisa ser medido; a dimensão 2.048, sozinha, não prova separabilidade das classes.

Treinamento, checkpoint e custo observado

A cabeça foi treinada com cross-entropy e AdamW, taxa 10^{-3} e weight decay 10^{-4}, lote 32 e precisão mista em CUDA. O orçamento era de até 20 épocas, com parada após cinco épocas

sem melhora na acurácia de validação. A execução terminou na sétima. A segunda época alcançou 100% na validação e definiu o checkpoint; a redução posterior da loss não mudou esse critério.

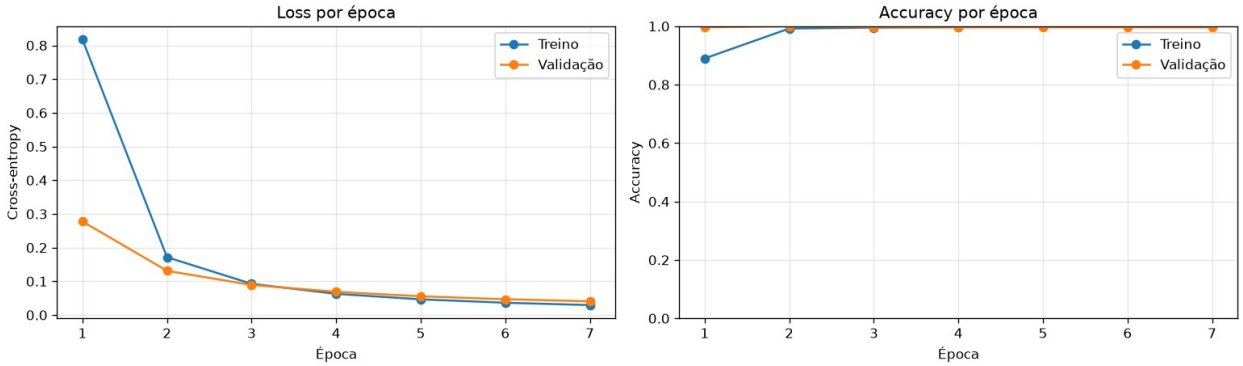


Figura 6 — Curvas de treino e validação de A3. A época 2 foi selecionada pela acurácia de validação. Fonte: execução v2 preservada.

Os logs registraram 7,88 s para a primeira época de treino e cerca de 6,4 a 6,8 s nas seguintes. O maior pico de memória alocada pelo PyTorch foi 447 MiB. Essa medida se refere ao alocador do framework durante a época instrumentada; não representa o consumo total da GPU, a memória reservada por outros processos ou a duração completa do notebook. A configuração priorizou velocidade com cuDNN benchmark e TF32, portanto a semente fixa não garante reprodução bit a bit.

Teste, erro observado e propostas

O checkpoint selecionado acertou 270 das 271 imagens de teste, acurácia de 99,6310%. Em bike, foram 54 acertos em 55 exemplos; nas outras seis classes, o recall foi 100%. O relatório de classificação mostra precisão menor em cars, consistente com a única bicicleta classificada como carro. As métricas arredondadas para duas casas podem aparecer como 1,00 e esconder esse erro; a contagem inteira permanece a referência.

A inspeção de três imagens por classe mostrou variações de pose, distância e fundo, além de ilustrações e coexistência de objetos. Essa amostra ajuda a propor transformações, mas não explica a causa do erro específico de teste. A tabela 12 descreve intervenções futuras; nenhuma foi aplicada ao baseline reportado.

Tabela 12 — Augmentation proposta para testar em A3.

Transformação	Motivo	Risco e avaliação
Flip horizontal	Variação de orientação de veículos e animais	Testar p=0,5 isoladamente; revisar texto e sinais direcionais
Rotação leve	Poses e enquadramentos inclinados	Até 10°; evitar posturas artificiais
Color jitter	Variação de iluminação e cor	Brilho, contraste e saturação até 0,1; preservar contraste útil
Recorte e escala	Objetos próximos ou de corpo inteiro	Preservar o objeto principal; medir perda de cobertura

Feature extraction reduz o custo de ajuste e é uma referência útil com poucos dados. Fine-tuning permite adaptar as representações, mas exige mais memória e controle de sobreajuste. Uma comparação futura poderia descongelar os últimos blocos com taxa menor, mantendo as partições e o orçamento definidos. ResNet-18 e EfficientNet-B0 também podem servir de referências de custo; não foram treinadas em A3.

A acurácia alta descreve esta divisão. A auditoria de caminhos não elimina duplicatas visuais, e o teste de 271 imagens não mede comportamento em novas fontes. A escolha para uma aplicação deve incluir avaliação externa e medidas de latência, em vez de se apoiar apenas no percentual de acertos deste conjunto.

6 A4 Estudo de caso de raio X e geração sintética

Problemas do estudo de caso

A atividade examina um projeto de classificação de radiografias e pergunta se acrescentar imagens sintéticas de COVID muda o recall no mesmo teste real. Os cinco problemas abaixo pertencem ao cenário da atividade. As correções propostas não devem ser atribuídas automaticamente a todas as versões da implementação anterior. O uso clínico de imagem torácica depende do contexto e da confirmação diagnóstica; este experimento não valida uma ferramenta de diagnóstico (OMS, 2020).

Tabela 13 — Problemas metodológicos e ações de correção.

Problema	Efeito sobre a avaliação	Ação
Escala desigual das entradas	Detalhes e geometria inconsistentes	Padronizar resolução, canais e normalização; auditar qualidade
Desequilíbrio de classes	Acurácia global pode esconder falhas em COVID	Usar métricas por classe; pesos definidos nos reais de treino
Divisão com risco de vazamento	Exames correlacionados podem inflar métricas	Separar pacientes e estudos; conferir duplicatas e origem
Transferência de domínio	Características e atalhos podem depender da fonte	Comparar adaptação e avaliar por hospital/equipamento
Ausência de augmentation no cenário	Pouca cobertura de variações de captura	Testar transformações plausíveis no treino e medir seu efeito

Coorte e partições preservadas

A coorte técnica tem 1.200 imagens: 840 Normal, 240 Pneumonia e 120 COVID-19. A execução de 08/10/2026 preservou o manifesto congelado e conferiu seu hash. Grupos de similaridade perceptual e duplicatas foram auditados, mas não há identificadores clínicos de pacientes. Não é possível afirmar independência por paciente. Permanecem pendentes a correspondência das imagens agregadas às fontes originais, os direitos de uso por imagem e a revisão de desidentificação, conforme a política da coorte.

Tabela 14 — Imagens reais por classe nas partições de A4.

Classe	Treino	Validação	Teste
Normal	600	120	120
Pneumonia	171	34	35
COVID-19	86	17	17
Total	857	171	172

Somente as 857 imagens reais de treino foram acessadas pela GAN. Validação e teste permaneceram reais e inalterados. A falta de IDs e a possível associação entre classe e origem limitam as conclusões mesmo quando os arquivos e grupos perceptuais estão separados. Uma reconstrução adequada da coorte deverá registrar paciente, estudo e fonte antes de nova avaliação.

Arquitetura e atualização da cGAN

Na cGAN, a classe condiciona tanto o gerador quanto o discriminador (Mirza e Osindero, 2014). O gerador concatena ruído de 100 dimensões com embedding de classe de dimensão 16. Uma projeção linear produz 512 canais em uma grade 4 × 4; cinco convoluções transpostas ampliam a resolução até 128 × 128, com canais 512, 256, 128, 64, 32 e 1. BatchNorm e ReLU são usadas nas etapas internas, e Tanh produz a saída em escala compatível com [-1,1].

O discriminador transforma a condição em um mapa 128 × 128, concatena esse mapa à imagem em tons de cinza e aplica convoluções com LeakyReLU. A configuração principal usa normalização espectral nas convoluções e na camada linear final. Essa técnica controla a norma dos pesos do discriminador (Miyato et al., 2018); seu efeito nesta implementação é examinado pela ablação, não presumido.

O treinamento usa BCEWithLogitsLoss e Adam com taxa 2×10^{-4} e betas (0,5; 0,999), lote 32 e 60 épocas. Primeiro, o discriminador recebe reais e sintéticas desconectadas do grafo do gerador. Depois, seus parâmetros e buffers são preservados durante a atualização do gerador. O alvo real suavizado é 0,9. Perdas e grades com ruído fixo permitem acompanhar a execução, mas loss finita ou baixa não certifica anatomia.

Comparação pareada da utilidade dos sintéticos

Foram geradas 86 imagens com a condição COVID-19, na proporção 1:1 com os 86 exemplos reais dessa classe no treino. A origem sintética e os hashes foram registrados. Condicionar em COVID define a entrada do modelo; não confirma que a imagem produzida contém achados da doença. Os candidatos receberam verificações computacionais, sem revisão clínica.

A comparação usa EfficientNet-B0, uma CNN cuja proposta relaciona profundidade, largura e resolução (Tan e Le, 2019). Os pesos ImageNet locais são seguidos de uma cabeça para três classes e fine-tuning completo. O braço A usa reais; o B acrescenta os sintéticos somente ao treino. Em cada uma das sementes 2026, 2027 e 2028, os dois braços começam com os mesmos pesos. Partições, pesos de classe calculados nos reais, augmentation e seleção foram mantidos iguais.

Cada classificador recebeu 12 épocas e 27 atualizações por época, total de 324, lote 32 e AdamW com taxa 10^{-4}. As entradas têm 160 × 160 pixels. A augmentation compartilhada usa rotações até 5°, deslocamentos até 3% e variações de brilho e contraste de 10%. A primeira época com maior F1 macro de validação determina o checkpoint. A decisão argmax e a quantidade de sintéticos foram fixadas antes do teste.

Tabela 15 — Recall de COVID, falsos negativos e F1 macro no mesmo teste real.

Semente	Braço	Recall COVID	FN / 17	F1 macro
2026	Reais	82,35%	3 / 17	0,9331
2027	Reais	82,35%	3 / 17	0,9466
2028	Reais	76,47%	4 / 17	0,9359
2026	Reais + sintéticos	76,47%	4 / 17	0,9326
2027	Reais + sintéticos	82,35%	3 / 17	0,9495
2028	Reais + sintéticos	82,35%	3 / 17	0,9574

Os recalls médios foram 80,39% nos dois braços. Por semente, as diferenças do braço com sintéticos foram -5,88, 0 e +5,88 pontos percentuais. O teste contém apenas 17 imagens COVID; um erro altera o recall de um modelo em aproximadamente 5,88 pontos. A igualdade das médias não demonstra equivalência entre os métodos.

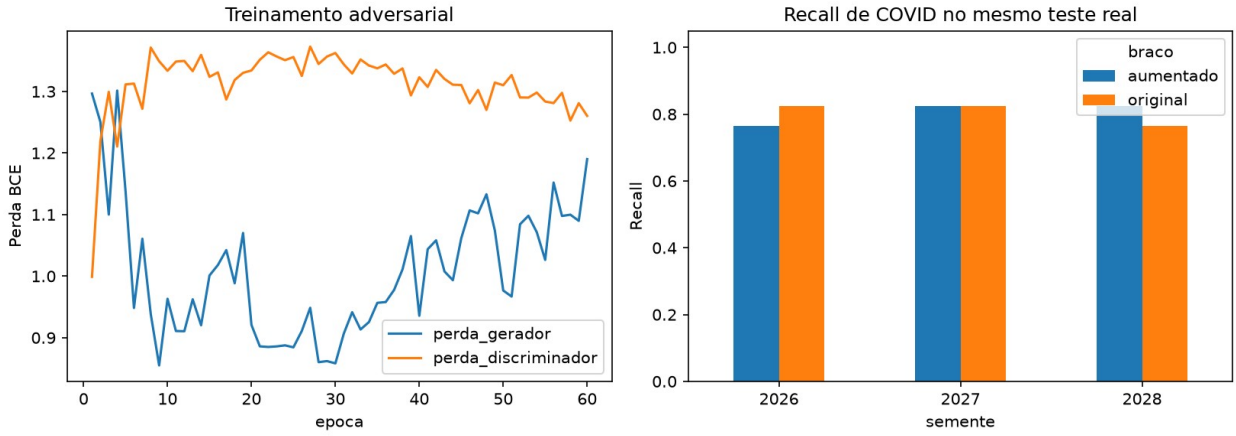


Figura 7 — Recall por semente e histórico adversarial da execução principal. Fonte: A4, 08/10/2026.

O bootstrap pareado com 10.000 reamostragens dos mesmos exemplos COVID resultou em intervalo de 95% da diferença média de -9,80 a +7,84 pontos percentuais. Os modelos foram mantidos fixos e a média das sementes foi calculada em cada reamostragem. O intervalo admite piora ou melhora e não incorpora novas GANs, hospitais ou pacientes independentes. A evidência atual sustenta ausência de ganho médio observado, com incerteza ampla.

Ablação de normalização espectral e suavização

A execução atual inclui a ablação que não havia sido feita no documento histórico da atividade 4.1. Foram comparadas uma referência sem normalização espectral e sem suavização e uma configuração com as duas estratégias. São três pares de sementes, 60 épocas e 26 passos adversariais por época. Os hashes dos pesos iniciais e das partições coincidem dentro de cada par. Dados, ruído, amostragem e otimizadores foram controlados; o teste não selecionou a mitigação.

A janela das dez últimas épocas foi definida antes da execução. O posto efetivo resume a distribuição de energia dos valores singulares de 64 miniaturas de 32 × 32 geradas com ruído fixo. A distância RMS mediana mede separação entre pares, e RMS abaixo de 0,02 identifica pares quase idênticos nesse diagnóstico. A saturação combina a fração de reais com saída do discriminador acima de 0,99 e sintéticas abaixo de 0,01. Esses indicadores operacionais não medem modos anatômicos ou qualidade diagnóstica.

Tabela 16 — Média na janela final da ablação pareada.

Semente	Posto: referência	Posto: mitigada	Saturação: ref.	Saturação: mit.
2026	9,1576	9,3424	3,2031%	0,0000%
2027	7,6701	7,8741	1,7969%	0,0000%
2028	9,0730	9,8287	1,4062%	0,0000%

O posto efetivo médio passou de 8,6336 para 9,0151, aumento de 4,42%, presente nos três pares. A saturação média caiu de 2,1354% para zero. A média das distâncias medianas RMS foi 0,1908 na referência e 0,1880 na mitigada, sem melhora uniforme. Não houve perdas ou gradientes não finitos, nem pares quase idênticos pelo corte final. A referência exploratória de 64 imagens COVID reais de treino teve posto 16,3471; esse valor contextualiza o indicador, sem definir um limite de aceitação clínica.

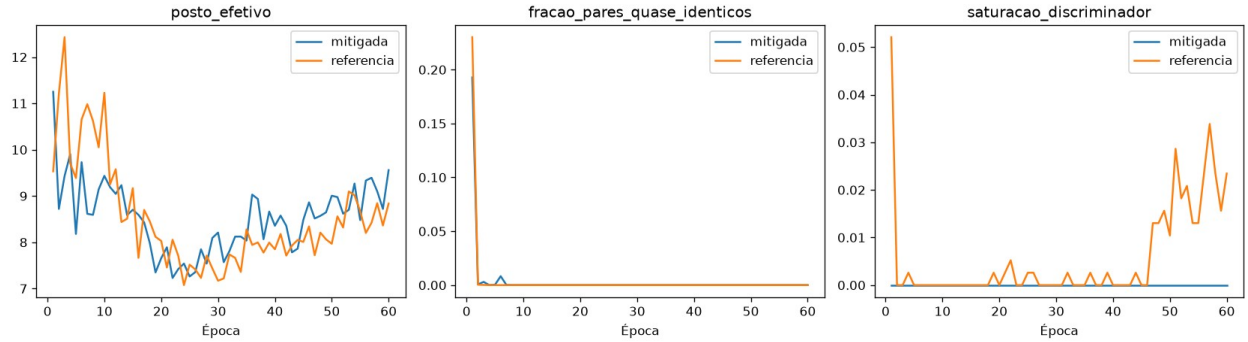


Figura 8 — Diagnósticos da ablação pareada da GAN. Fonte: A4, 08/10/2026.

As grades mostram repetição estrutural e artefatos quadriculados, compatíveis com diversidade reduzida ou colapso parcial. Os indicadores não demonstram colapso completo. A melhora medida é modesta e se limita aos diagnósticos de treinamento. Como as duas estratégias foram ativadas juntas, a comparação não isola o efeito de cada uma. Também não houve novo treino dos classificadores com candidatos escolhidos pela ablação.

Plano de reconstrução e conclusão do estudo

O próximo ciclo deve começar pela finalidade clínica e pela coorte: confirmar rótulos, vincular cada imagem à fonte e reunir exames do mesmo paciente. O split deve ser refeito por paciente, com avaliação externa por hospital ou período. No desenvolvimento, comparar uma referência simples com transferência e fine-tuning, investigar atalhos de origem e examinar calibração e erros por subgrupo disponível.

Uma nova avaliação dos sintéticos exige revisão especializada de anatomia, análise de possível memorização e comparação pareada com pacientes independentes. Qualquer quantidade de candidatos deve ser definida antes do teste ou ajustada apenas na validação. Um piloto clínico dependeria de critérios definidos pela equipe responsável e de avaliação prospectiva supervisionada. Esses passos são propostas; não foram executados aqui.

A GAN foi treinada e a comparação foi realizada, mas o benefício esperado não apareceu no recall médio. A ablação reduziu saturação e aumentou um indicador de diversidade; isso não altera a conclusão sobre utilidade no teste nem resolve as pendências da coorte. Com estes dados, não há base para substituir o treinamento com reais por uma estratégia que dependa dos sintéticos ou para usar os modelos em decisões clínicas.

7 A4 Estudo de caso de tráfego urbano

Cenário e objetivo operacional

O estudo analisa 800 frames, três classes de tráfego — livre, moderado e congestionado — e doze câmeras, com imagens diurnas e ensolaradas. A fonte é atividade_4_2_trafego_urbano.docx. Não há implementação, treinamento ou resultados de produção. Os efeitos discutidos são riscos do desenho apresentado e as soluções são propostas para uma futura avaliação.

Antes de escolher o modelo, a equipe precisa definir o que cada classe significa. Ocupação da via em um frame e fluxo ao longo do tempo são medidas diferentes. Uma imagem pode mostrar muitos veículos sem indicar se estão parados. Se a finalidade inclui velocidade, duração de filas ou fluxo, serão necessárias sequências temporais ou sensores adicionais, com referência de medição.

Quatro problemas e suas correções

O primeiro problema é a baixa diversidade de horário e clima. Luz noturna, reflexos, chuva e neblina alteram a aparência das vias. Isso pode provocar erros, mas a queda não foi medida. A coleta deve cobrir essas condições com vídeos reais e preservar exemplos para teste. Augmentation de iluminação ou clima pode ser comparada quando preservar o rótulo; não substitui observações reais das condições de operação.

O segundo é a dependência das doze câmeras. Frames de uma mesma câmera compartilham fundo e perspectiva; frames próximos também são correlacionados. Uma divisão aleatória pode colocar a mesma situação em treino e teste. A avaliação precisa separar câmeras, sessões e períodos, incluindo câmeras inéditas. Regiões da via e calibração de perspectiva podem ajudar, mas uma homografia em um plano conhecido não elimina todas as oclusões.

O terceiro é o volume reduzido de exemplos independentes. Se as classes fossem balanceadas, haveria cerca de 267 frames por classe; as contagens reais não foram informadas. A coleta deve priorizar eventos distintos, condições raras e casos ambíguos, com espaçamento temporal e controle de duplicatas. Dois anotadores podem revisar fronteiras entre moderado e congestionado. Curvas de aprendizado ajudam a decidir onde novos dados acrescentam cobertura.

O quarto é presumir que pesos ImageNet dispensam adaptação ao tráfego. Pré-treinamento é uma escolha válida, mas sua utilidade varia com a distância entre tarefas (Yosinski et al., 2014). A avaliação deve comparar backbone congelado e fine-tuning gradual nas mesmas partições. Uma referência de ocupação e uma abordagem com informação temporal podem esclarecer o que o classificador de frames está deixando de medir.

Tabela 17 — Critérios propostos para verificar as correções de tráfego.

Problema	Risco operacional	Verificação proposta
Horário e clima restritos	Alertas e estimativas inadequados em condições novas	Recall/F1 por classe em vídeos noturnos e com chuva
Câmeras compartilhadas	Queda em pontos novos e retrabalho de adaptação	Separar locais; relatar métricas por câmera conhecida/inédita
800 frames correlacionados	Oscilações e pouca cobertura de eventos raros	Concordância de rótulos; curvas de aprendizado; intervalos por grupo
Transferência sem avaliação	Confusão entre ocupação e movimento	Comparar congelamento, ajuste e sequência temporal; medir custo

Protocolo de avaliação e piloto

O inventário inicial deve registrar câmera, data, horário, clima e evento, além dos critérios de anotação. Treino e validação devem usar sessões distintas, e um teste preservado deve conter períodos separados e câmeras que não participam da adaptação. Cenas contíguas ficam no mesmo grupo. Os intervalos de desempenho precisam considerar grupos temporais ou câmeras, em vez de tratar todos os frames como independentes.

Tabela 18 — Medidas previstas para o estudo de tráfego; sem valores experimentais.

Medida	Finalidade	Unidade / recorte
F1 macro e recall de congestionamento	Cobertura e confusões entre classes	Por classe, câmera, horário e clima
Matriz de confusão	Examinar livre/moderado/congestionado	Contagens no teste preservado
Atraso de detecção	Tempo entre evento e alerta	Segundos; eventos anotados
Latência e capacidade	Viabilidade no hardware de implantação	ms por decisão e decisões por segundo
Estabilidade temporal	Oscilações e custo da suavização	Trocas de classe e atraso adicional

As comparações devem manter partições e orçamento equivalentes. O piloto começa em paralelo ao procedimento existente e com supervisão. A equipe de operação define os limites aceitáveis de qualidade e atraso antes de consultar o teste. Câmera obstruída, dado fora do domínio ou falha de processamento devem ser sinalizados. Suavização temporal pode reduzir oscilações, mas seu atraso também precisa ser medido. Mudanças de câmera e distribuição dos dados exigem reavaliação e possibilidade de retorno ao procedimento anterior.

O protocolo precisa ser testado com dados das condições de operação e partições separadas por lugar e período. Os 800 frames não permitem estimar desempenho noturno ou benefício de uma nova arquitetura.

8 Discussão integrada e conclusões

O que os resultados permitem concluir

A1 mostrou que o checkpoint pré-treinado não garantiu a melhor classificação no recorte de frutas. A3, por sua vez, obteve 270/271 acertos com apenas uma cabeça treinável. Os resultados não se contradizem: os dados, os tamanhos dos modelos e os protocolos são diferentes. Tampouco permitem montar um ranking geral de ViT e CNN. A contribuição comum é mostrar que a decisão precisa passar pelo teste definido para cada tarefa.

Em A2, a limitação aparece na interpretação do score. O CLIP recupera afinidades semânticas, inclusive quando um objeto ou uma ação não está visível. Em A4, a condição de classe do gerador também não certifica o conteúdo clínico da imagem. Nos dois casos, uma saída compatível com a descrição do modelo ainda exige uma referência externa para confirmar o significado que se pretende atribuir a ela.

Tabela 19 — Síntese das atividades, conclusões e próxima verificação.

Atividade	Resultado / entrega	Limite que orienta o próximo passo
A1	F1 macro: 0,9968 do zero; 0,9908 pré-treinado	Repetir sementes; testar fundos variados e custo de inferência
A2	Ranking e oito buscas em 300 anúncios	Anotar relevância/presença; medir precision@k e limiares
A3	270/271 acertos com backbone congelado	Examinar duplicatas visuais e dados externos
A4 — raio-X	Recall médio igual; melhora modesta na ablação	Revisar coorte, pacientes e anatomia; validar externamente
A4 — tráfego	Plano de coleta, avaliação e piloto	Executar protocolo com câmeras e períodos independentes

Validação, custo e qualidade da evidência

O checkpoint é parte do resultado. Em A1 e A3, o último estado de treino não era o escolhido pela validação. A restauração integral dos pesos em A1 tornou a comparação verificável. Em A4, a inicialização pareada e o mesmo número de atualizações reduziram diferenças de procedimento entre os braços, mas não resolveram a falta de IDs clínicos. Conferir o código e o artefato salvo é necessário; a qualidade dos dados continua sendo uma questão separada.

As medições de custo também têm escopos distintos. A3 registra memória alocada pelo PyTorch e duração de épocas; A1 registra duração de fases; A2 registra uma execução em CPU. Não há benchmark comum de latência ou energia. O menor custo de ajuste de uma cabeça congelada é uma razão para incluí-la como referência, sem presumir que será a melhor opção em qualquer domínio.

Conclusão

O projeto executou classificação com ViT e ResNet, recuperação semântica com CLIP e geração condicional com comparação de classificadores. Os resultados são rastreáveis aos notebooks e aos arquivos locais. O ganho esperado dos sintéticos não apareceu no recall médio, e o ranking semântico incluiu falsos positivos. Registrar essas falhas evita que a conclusão dependa apenas dos exemplos de sucesso.

A etapa seguinte deve atacar os limites mais concretos: imagens externas para A1 e A3, anotações de relevância para A2 e reconstrução da coorte por paciente em A4. Para tráfego, é preciso executar o protocolo proposto antes de afirmar desempenho. A escolha de arquitetura virá dessas avaliações, considerando qualidade e custo no uso pretendido.

9 Referências

Os artigos fundamentam os mecanismos dos modelos. Os números experimentais pertencem às execuções locais identificadas nos capítulos e no apêndice D. Consulta das fontes digitais: 09/10/2026. As pendências de origem da coorte de raio-X continuam registradas; citar um repositório não confirma a correspondência de cada imagem agregada.

DOSOVITSKIY, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. 2020. https://arxiv.org/abs/2010.11929

DEVLIN, J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2018. https://arxiv.org/abs/1810.04805

TOUVRON, H. et al. Training data-efficient image transformers & distillation through attention. 2020. https://arxiv.org/abs/2012.12877

LIU, Z. et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. 2021. https://arxiv.org/abs/2103.14030

MUREȘAN, H.; OLTEAN, M. Fruit recognition from images using deep learning. Versão revisada, 2018. https://arxiv.org/abs/1712.00580

HUGGING FACE. Model card: google/vit-base-patch16-224-in21k. https://huggingface.co/google/vit-base-patch16-224-in21k Consulta: 09/10/2026.

RADFORD, A. et al. Learning Transferable Visual Models From Natural Language Supervision. 2021. https://arxiv.org/abs/2103.00020

ROFFO, G.; VINCIARELLI, A. Personality in Computational Advertising: A Benchmark. EMPIRE, 2016. https://ceur-ws.org/Vol-1680/paper3.pdf

HE, K. et al. Deep Residual Learning for Image Recognition. 2015. https://arxiv.org/abs/1512.03385

MIRZA, M.; OSINDERO, S. Conditional Generative Adversarial Nets. 2014. https://arxiv.org/abs/1411.1784

TAN, M.; LE, Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. 2019. https://arxiv.org/abs/1905.11946

MIYATO, T. et al. Spectral Normalization for Generative Adversarial Networks. 2018. https://arxiv.org/abs/1802.05957

YOSINSKI, J. et al. How transferable are features in deep neural networks? 2014. https://arxiv.org/abs/1411.1792

ORGANIZAÇÃO MUNDIAL DA SAÚDE. Use of chest imaging in COVID-19: a rapid advice guide. 2020. https://www.who.int/publications/i/item/use-of-chest-imaging-in-covid-19

HUGGING FACE. CLIP: documentação de modelo. https://huggingface.co/docs/transformers/model_doc/clip

PYTORCH. DCGAN tutorial. https://docs.pytorch.org/tutorials/beginner/dcgan_faces_tutorial.html

KAGGLE. Fruits-360 (moltean/fruits), versão local 107. https://www.kaggle.com/datasets/moltean/fruits

KAGGLE. ADS-16 Dataset (groffo/ads16-dataset), versão local 1. https://www.kaggle.com/datasets/groffo/ads16-dataset

KAGGLE. Images Dataset (pavansanagapati/images-dataset), versão local 1. https://www.kaggle.com/datasets/pavansanagapati/images-dataset

RODRIGUES, Kevin William Alves. Notebooks A1 a A4 e documentos das atividades 4.1 e 4.2. Projeto local da disciplina, 2026. Inventário no apêndice D.

10 Apêndices técnicos

Apêndice A — Descrições e consultas de CLIP

As descrições foram mantidas como no notebook. Os caminhos curtos Ads/categoria/arquivo abaixo identificam slots únicos no corpus auditado; o CSV preserva o caminho relativo completo e o dispositivo da execução é registrado separadamente. Scores são similaridades de cosseno de embeddings normalizados.

Tabela A1 — Vinte descrições fixas de A2.

Conceito	Descrição em inglês
person	an advertisement featuring a person
vehicle	an advertisement featuring a car or another vehicle
food	an advertisement featuring food
beverage	an advertisement featuring a beverage
electronics	an advertisement featuring an electronic device
clothing	an advertisement featuring clothing or shoes
beauty	an advertisement featuring a beauty or cosmetic product
child	an advertisement featuring a baby or child
animal	an advertisement featuring an animal or pet
sports	an advertisement featuring sports or exercise equipment
jewelry	an advertisement featuring jewelry or a watch
instrument	an advertisement featuring a musical instrument
tools	an advertisement featuring tools or hardware
home	an advertisement featuring furniture or a home interior
office	an advertisement featuring stationery or office supplies
nature	an advertisement featuring outdoor scenery or nature
package	an advertisement featuring product packaging
isolated_product	an advertisement showing a single product on a plain background
text_logo	an advertisement dominated by text and a logo
people_using_product	an advertisement showing people using a product

Consulta 1: an advertisement for a consumer product

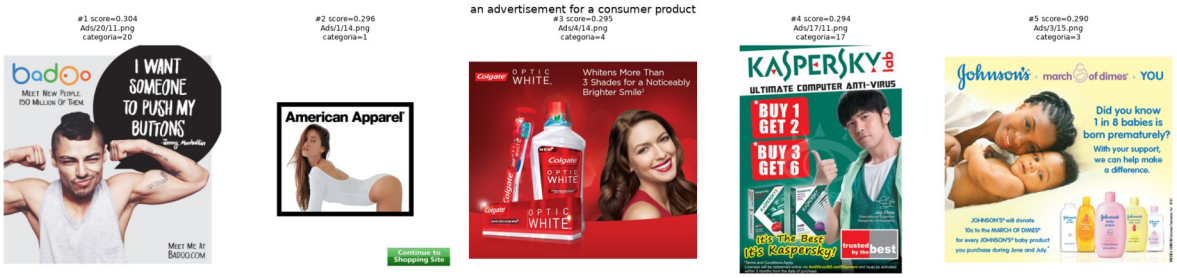


Figura A1 — Cinco resultados da consulta 1. Fonte: A2 v3.

Tabela A2 — Caminhos e scores da consulta 1.

Posição	Caminho curto	Score
1	Ads/20/11.png	0,303571
2	Ads/1/14.png	0,295796
3	Ads/4/14.png	0,295139
4	Ads/17/11.png	0,294180
5	Ads/3/15.png	0,290333

Consulta 2: a product on a plain background



Figura A2 — Cinco resultados da consulta 2. Fonte: A2 v3.

Tabela A3 — Caminhos e scores da consulta 2.

Posição	Caminho curto	Score
1	Ads/3/3.png	0,267820
2	Ads/15/8.png	0,265204
3	Ads/9/7.png	0,264820
4	Ads/13/1.png	0,263902
5	Ads/8/3.png	0,262694

Consulta 3: a person using a product



Figura A3 — Cinco resultados da consulta 3. Fonte: A2 v3.

Tabela A4 — Caminhos e scores da consulta 3.

Posição	Caminho curto	Score
1	Ads/3/3.png	0,289503
2	Ads/3/4.png	0,273873
3	Ads/18/3.png	0,273347
4	Ads/4/7.png	0,271307
5	Ads/3/9.png	0,268199

Consulta 4: a car driving outdoors



Figura A4 — Cinco resultados da consulta 4. Fonte: A2 v3.

Tabela A5 — Caminhos e scores da consulta 4.

Posição	Caminho curto	Score
1	Ads/2/3.png	0,259314
2	Ads/2/4.png	0,243898
3	Ads/2/7.png	0,240493
4	Ads/2/1.png	0,236003
5	Ads/2/2.png	0,235327

Consulta 5: a healthy food product



Figura A5 — Cinco resultados da consulta 5. Fonte: A2 v3.

Tabela A6 — Caminhos e scores da consulta 5.

Posição	Caminho curto	Score
1	Ads/16/15.png	0,271996
2	Ads/4/8.png	0,270433
3	Ads/16/7.png	0,268872
4	Ads/16/2.png	0,266881
5	Ads/16/9.png	0,266371

Consulta 6: a luxury watch with an elegant design

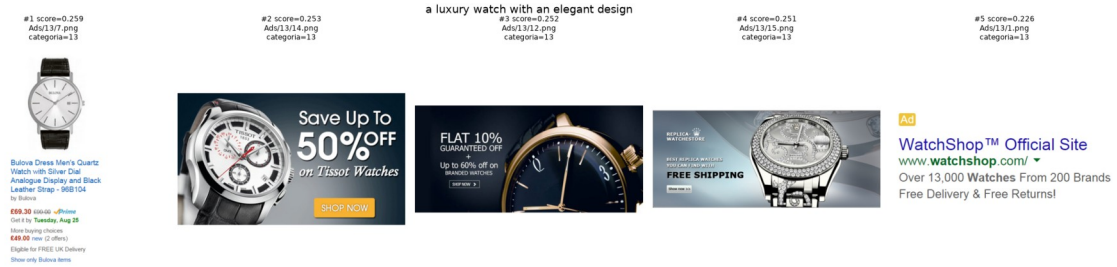


Figura A6 — Cinco resultados da consulta 6. Fonte: A2 v3.

Tabela A7 — Caminhos e scores da consulta 6.

Posição	Caminho curto	Score
1	Ads/13/7.png	0,259352
2	Ads/13/14.png	0,252603
3	Ads/13/12.png	0,252407
4	Ads/13/15.png	0,250563
5	Ads/13/1.png	0,226447

Consulta 7: a colorful advertisement made for children



Figura A7 — Cinco resultados da consulta 7. Fonte: A2 v3.

Tabela A8 — Caminhos e scores da consulta 7.

Posição	Caminho curto	Score
1	Ads/19/5.png	0,259487
2	Ads/10/15.png	0,259042
3	Ads/15/5.png	0,255782
4	Ads/15/14.png	0,244719
5	Ads/5/2.png	0,243725

Consulta 8: an advertisement that suggests excitement and adventure

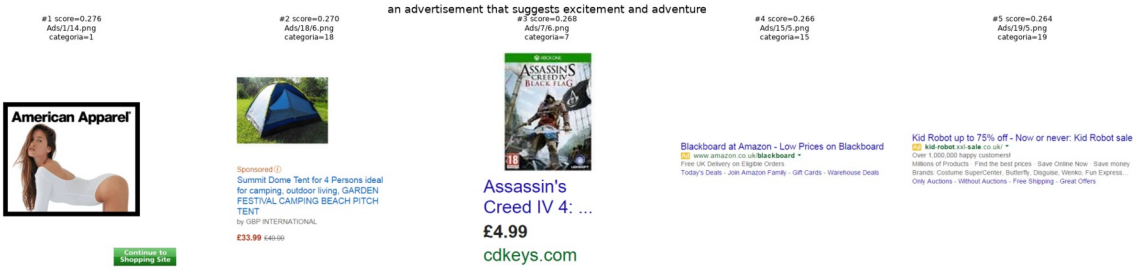


Figura A8 — Cinco resultados da consulta 8. Fonte: A2 v3.

Tabela A9 — Caminhos e scores da consulta 8.

Posição	Caminho curto	Score
1	Ads/1/14.png	0,276161
2	Ads/18/6.png	0,270124
3	Ads/7/6.png	0,268183
4	Ads/15/5.png	0,266489
5	Ads/19/5.png	0,263991

Apêndice B — Métricas por classe e sensibilidade

Em A1, as classes seguem a ordem fixa do notebook. Precision, recall e F1 são mostrados com quatro casas; os CSVs preservam a precisão numérica completa.

Tabela B1 — Métricas por classe de A1.

Classe	P zero	R zero	F1 zero	P pré	R pré	F1 pré
Apple Braeburn 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Apple Golden 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Apple Granny Smith 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Apple Red Delicious 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Banana 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Banana Lady Finger 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Banana Red 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Pepper Green 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Pepper Orange 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Pepper Red 1	1,0000	0,9865	0,9932	1,0000	1,0000	1,0000
Pepper Yellow 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Tomato 1	1,0000	0,9715	0,9856	1,0000	1,0000	1,0000
Tomato 2	0,9956	0,9956	0,9956	0,8721	1,0000	0,9317
Tomato 3	0,9572	1,0000	0,9781	1,0000	1,0000	1,0000
Tomato 4	1,0000	0,9812	0,9905	1,0000	0,7937	0,8850
Avocado 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Kiwi 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Lemon 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Pineapple 1	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
Strawberry 1	0,9880	1,0000	0,9939	1,0000	1,0000	1,0000

P = precision; R = recall; zero = ViT do zero; pré = ViT pré-treinado. Os suportes do Test são os do catálogo oficial do recorte. A tabela 7 apresenta as contagens das classes com erros.

Tabela B2 — Sensibilidade dos vinte conceitos de A2.

Conceito	≥ 0,20	≥ 0,25	≥ 0,30
person	245	56	2
vehicle	178	23	3
food	182	20	2
beverage	163	13	0
electronics	226	31	1
clothing	177	25	2
beauty	188	17	2
child	195	31	3
animal	198	18	0
sports	192	18	0
jewelry	137	13	1
instrument	183	20	1
tools	231	35	2
home	155	10	1
office	231	42	0
nature	221	34	0
package	285	75	0
isolated_product	298	197	4
text_logo	273	114	3
people_using_product	298	164	2

A figura B1 preserva os top-3 automáticos dos cinco líderes, inclusive os falsos positivos discutidos no capítulo 4. O tamanho de exibição foi ajustado à página, sem alterar os scores ou os exemplos.

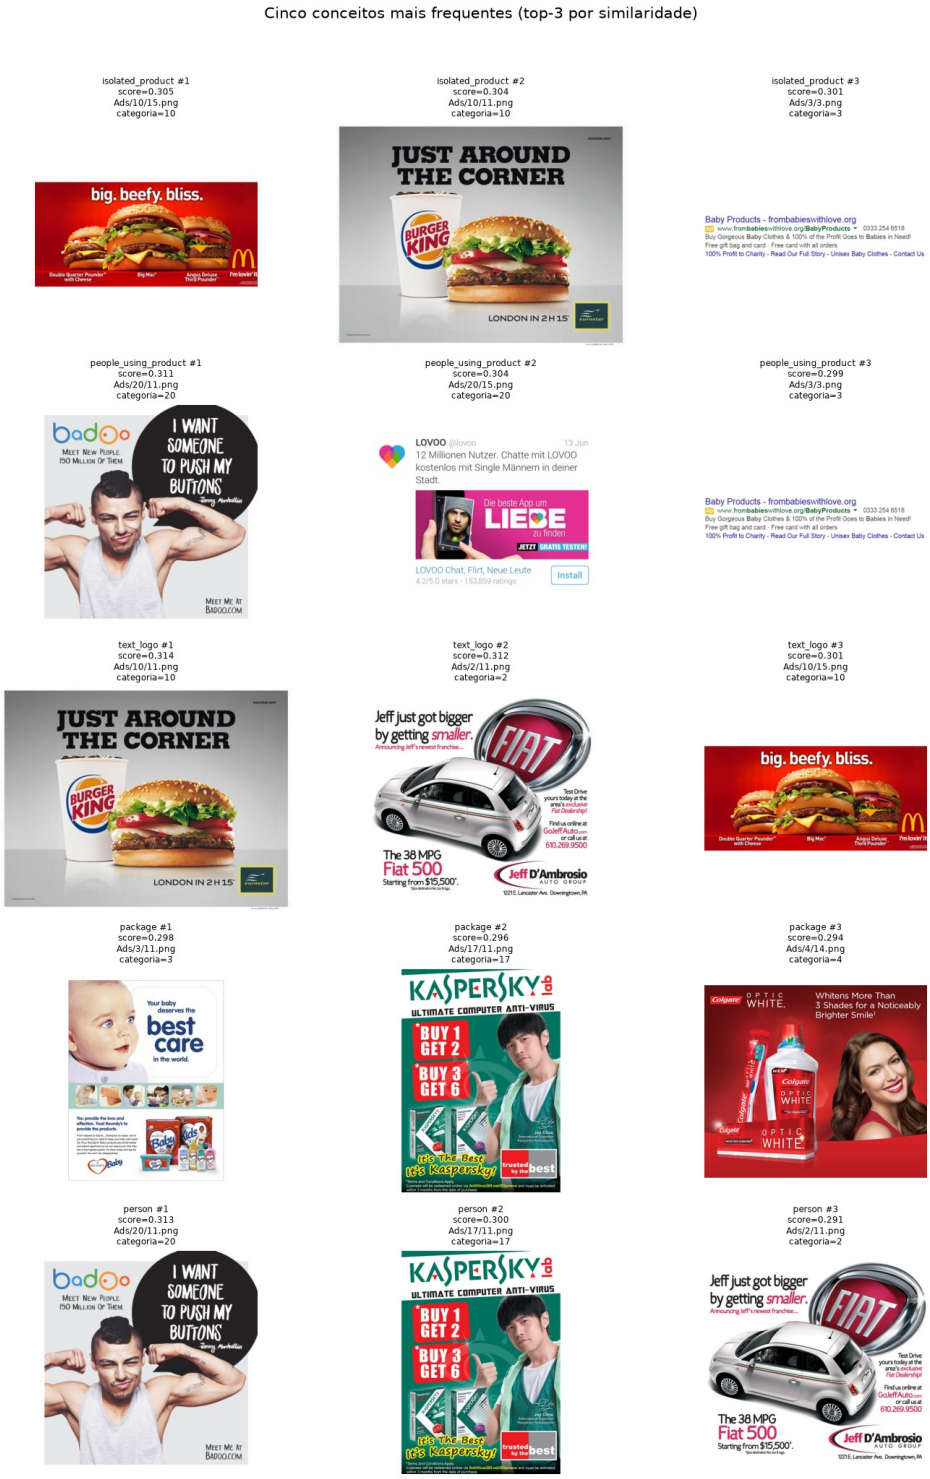


Figura B1 — Top-3 automático por conceito líder, com caminho e score. Fonte: A2 v3.

Métricas adicionais de A4

Tabela B3 — Indicadores de COVID por classificador de A4.

Semente / braço	Época escolhida	Precision	Especificidade	IC Wilson recall
2026 / reais	6	0,8750	0,9871	58,97% a 93,81%
2027 / reais	8	0,9333	0,9935	58,97% a 93,81%
2028 / reais	5	0,9286	0,9935	52,74% a 90,45%
2026 / sintéticos	10	0,9286	0,9935	52,74% a 90,45%
2027 / sintéticos	7	0,9333	0,9935	58,97% a 93,81%
2028 / sintéticos	12	1,0000	1,0000	58,97% a 93,81%

Os intervalos Wilson usam 17 exemplos COVID e descrevem cada modelo. O intervalo da diferença média usa bootstrap pareado, apresentado no capítulo 6. Nenhum desses cálculos resolve a ausência de independência por paciente.

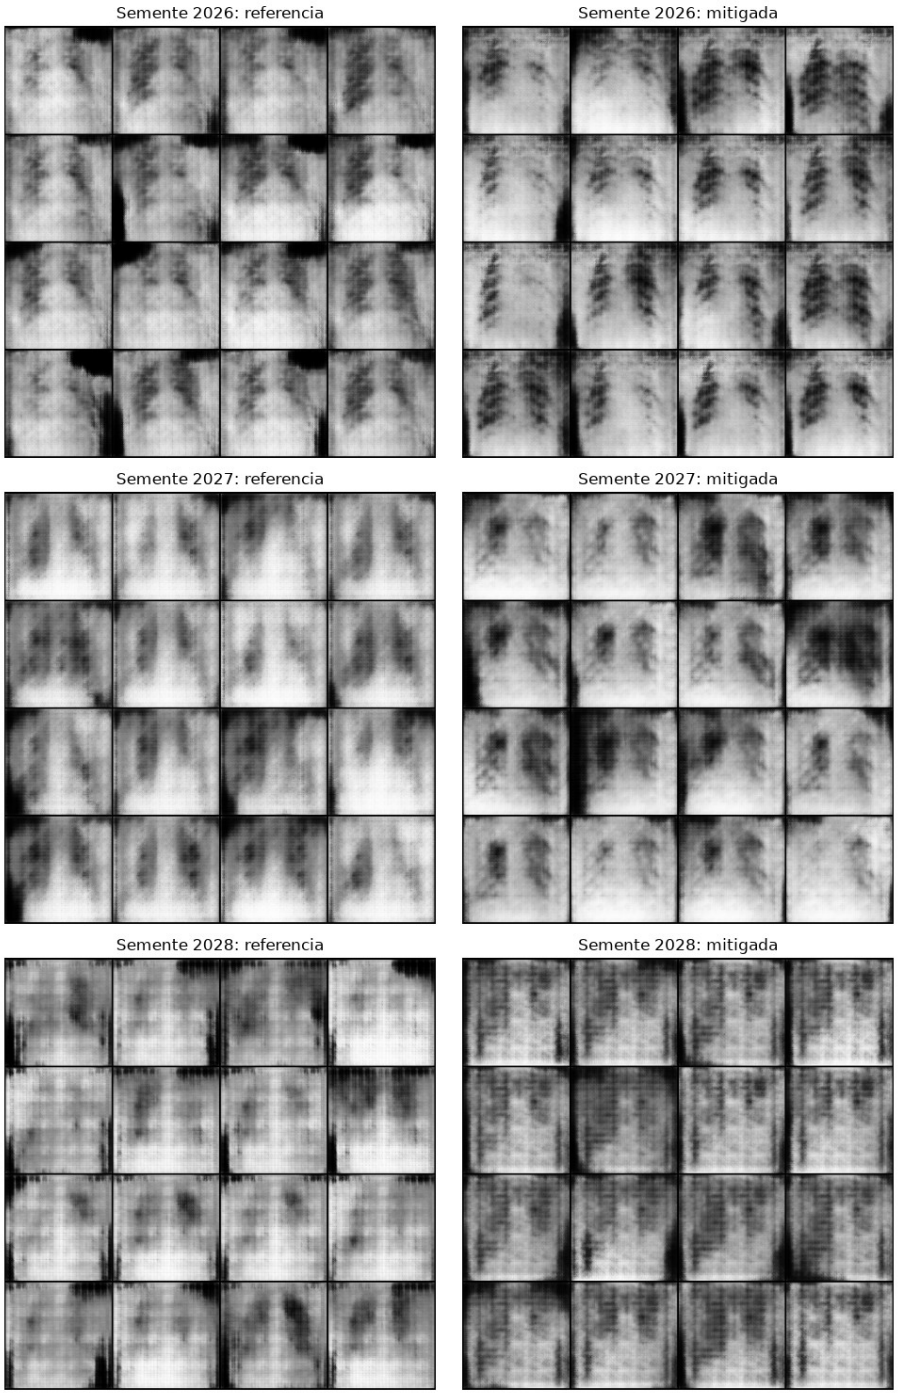


Figura B2 — Grades com ruído fixo na época 60: referência e mitigação, em três sementes. São imagens sintéticas, sem validação clínica. Fonte: A4, 08/10/2026.

Apêndice C — Configurações e verificações

Tabela C1 — Configurações resumidas, sem uniformizar protocolos distintos.

Ativ.	Seleção	Sementes / orçamento	Verificação
A1	Maior F1 macro de validação	42; zero até 15 épocas; cabeça 2; completo até 5	200 tensores restaurados; F1 recalculado igual ao selecionado
A2	Sem treinamento; corte 0,25 para contagens	20 prompts; 8 consultas; top-5	300 hashes únicos; normas L2 e ordenação conferidas
A3	Maior acurácia de validação	42; até 20 épocas; 7 realizadas	Backbone e BatchNorm congelados; 270/271 acertos
A4	Primeiro maior F1 macro de validação	2026–2028; GAN 60; classificador 12	Inicialização pareada; 324 atualizações; teste real preservado

A4 utiliza GAN com resolução 128 e classificador com 160 pixels; sua ablação mantém 26 passos por época em cada configuração. A execução principal e a ablação levaram aproximadamente 23,1 minutos na RTX 3050 de 6 GB. A referência real e a figura de grades foram calculadas depois, sem novos treinos. O tempo é o registro dessa execução, não uma garantia para outro ambiente.

Tabela C2 — Auditorias e limites de reprodutibilidade.

Registro	Resultado	Limite
A1: partições	Caminhos disjuntos; validação estratificada	Não comprova independência por sessão de captura
A1: restauração	Zero chaves ausentes/incompatíveis; tensores iguais	A compatibilidade precisa ser repetida se a biblioteca mudar
A2: catálogo	301 candidatos; 1 excluído; 300 hashes únicos	Hash exato não detecta toda semelhança visual
A3: auditoria	1.803 imagens legíveis; 7 classes	Uma divisão e cuDNN otimizado não garantem robustez externa
A4: coorte	Manifesto preservado; 0 IDs de pacientes	Grupos perceptuais não são grupos clínicos
A4: ablação	Pesos e dados pareados; janela final fixada	Efeito conjunto de duas estratégias; sem revisão anatômica

Apêndice D — Índice de evidências locais

Os caminhos são relativos à raiz do projeto. As pastas de resultados locais podem estar ignoradas pelo Git; o relatório incorpora os valores e figuras utilizados, mas não inclui datasets, pesos ou caches. O envio do DOCX permite revisar o texto; reproduzir a execução exige os arquivos e dependências descritos nos notebooks.

Tabela D1 — Artefatos usados na redação.

Ativ.	Arquivo ou pasta	Uso no relatório
A1	projeto-1/A1_vision_transformers.ipynb	Arquitetura, protocolo, logs e análises
A1	projeto-1/resultados/v3/	Métricas, curvas reconstruídas, ambiente, atenção e restauração
A2	projeto-2/A2_clip_ads16.ipynb	Contrato de corpus, prompts, consultas e inspeção
A2	projeto-2/resultados/v3/	Ranking, sensibilidade, consultas, confirmações e figuras
A3	projeto-3/A3_cnn_kaggle.ipynb	Auditoria, treino da cabeça e relatório de classificação
A3	projeto-3/resultados/v2/	Curvas, acurácia por classe e resultado preservado
A4	projeto-4/A4_estudo_caso_raio_x.ipynb	Implementação, controle pareado e ablação atual
A4	projeto-4/resultados/20261008_191210/	Manifesto, previsões, recall, protocolos e gráficos
A4	projeto-4/atividade_4_1_plano_de_acao.docx	Cinco problemas e plano; resultados históricos cotejados com a execução atual
Tráfego	projeto-4/atividade_4_2_trafego_urbano.docx	Cenário, problemas e protocolo analítico

A1 usa comparacao.csv, historico_vit_didatico.csv, metricas_por_classe.csv, restauracao.json e ambiente.json. A2 usa ranking.csv, sensibilidade.csv, consultas.csv e figuras/conceitos/confirmacoes_visuais.csv. A3 usa historico.csv, acuracia_por_classe.csv e resultados.json. Em A4, comparacao_recall.csv e os CSVs de previsões identificam cada braço e semente; ablacao/comparacao.csv e historico_completo.csv sustentam os diagnósticos.

As figuras 1 e 2 foram reconstruídas dos CSVs e logs de A1; as demais figuras experimentais foram incorporadas dos PNGs exportados. Matrizes e galerias sem pixels preservados nas saídas de A1 não foram inventadas. As contagens de erros foram obtidas dos recalls e suportes. Em tráfego, todas as medidas permanecem propostas, sem números de desempenho atribuídos ao sistema.